

GrafitoIA: Predição de Risco de Inadimplência em Empréstimos a Pequenos Negócios com Machine Learning, com Aplicação Potencial a Microempreendedores Individuais (MEI)

André Contarelli Lima ¹ Lucas Bittencourt de Oliveira ¹
Fernando Paiva¹
Nome Professor Orientador ^{1,2}

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<10410280, 10409476, 10416680@mackenzista.com.br>

2026

Resumo

Este trabalho apresenta o projeto do modelo GrafitoIA, uma abordagem baseada em aprendizado de máquina supervisionado para a predição do risco de inadimplência em concessões de crédito a pequenos negócios, motivado pelos desafios de sustentabilidade financeira enfrentados por Microempreendedores Individuais (MEI) no Brasil. Em decorrência da inexistência de bases públicas nacionais consolidadas e rotuladas com histórico de inadimplência nessa categoria empresarial, utilizou-se como base experimental o SBA National Dataset, disponibilizado pela U.S. Small Business Administration, contendo aproximadamente 899 mil registros históricos de empréstimos com rótulos reais de quitação integral ou baixa contábil. A pesquisa adota a Opção Framework por meio do ecossistema scikit-learn, estabelecendo um pipeline metodológico rigoroso composto por limpeza de atributos monetários, engenharia de variáveis, balanceamento amostral e comparação entre algoritmos supervisionados (Regressão Logística, Random Forest e Gradient Boosting). A avaliação prioriza métricas robustas para dados desbalanceados, com foco especial no recall da classe minoritária e na área sob a curva ROC. Como resultado esperado da etapa inicial, estabelece-se a fundamentação conceitual, o tratamento ético frente à generalização

transnacional de dados e a arquitetura preditiva que servirá de alicerce para integração futura ao aplicativo móvel Grafito.

Palavras-chave: *Aprendizado de máquina; Concessão de crédito; Inadimplência; Microempreendedor Individual; SBA National Dataset*

Abstract

This paper presents the GrafitoIA project, a supervised machine learning approach designed to predict loan default risk in small business financing, motivated by the financial sustainability challenges faced by Individual Microentrepreneurs (MEI) in Brazil. Due to the current absence of granular, publicly labeled Brazilian datasets concerning default outcomes for this business tier, the study employs the real-world SBA National Dataset from the U.S. Small Business Administration, comprising approximately 899,000 historical loan records labeled with actual repayment or charge-off status. Adopting the Framework Option via the scikit-learn library, this research establishes a standardized pipeline encompassing monetary string parsing, feature engineering, class imbalance mitigation, and comparative benchmarking among classification models (Logistic Regression, Random Forest, and Gradient Boosting). Model performance is primarily evaluated using metrics suited for imbalanced datasets, with particular emphasis on minority class recall and the area under the ROC curve. As expected outcomes of this initial stage, the study consolidates the conceptual foundation, ethical safeguards regarding cross-national data transferability, and the predictive baseline intended to support future risk-indicator integration into the Grafito mobile application.

Keywords: *Machine learning; Credit scoring; Loan default; Small business; SBA National Dataset.*

1. Introdução

O Microempreendedor Individual (MEI) é hoje uma das principais portas de formalização de pequenos negócios no Brasil. O país chegou a 13,1 milhões de MEIs ativos, com mais de 3,8 milhões de novos registros apenas em 2025 (SEBRAE apud PODER360, 2025). Apesar do crescimento expressivo, boa parte desses empreendedores segue gerenciando o negócio de forma manual ou por meio de planilhas genéricas, sem separar com clareza receitas pessoais e empresariais, o que dificulta o planejamento financeiro e o controle do estoque de produtos e insumos.

Esse cenário configura uma lacuna de pesquisa relevante para a área de Interação Humano-Computador e de sistemas de informação aplicados a pequenos negócios: como projetar aplicativos móveis que traduzam conceitos financeiros e de gestão de estoque em

uma linguagem acessível ao empreendedor sem formação em contabilidade ou administração, sem renunciar a recursos que efetivamente apoiem a tomada de decisão do dia a dia.

O objetivo geral deste trabalho é projetar, desenvolver e avaliar o Grafito, um aplicativo móvel iOS de gestão financeira e de estoque voltado a MEIs e trabalhadores autônomos. Os objetivos específicos são: (i) mapear as principais dificuldades de MEIs no controle financeiro e de estoque do próprio negócio; (ii) projetar uma interface que unifique esses dois controles em um único fluxo de uso; (iii) implementar um protótipo funcional em SwiftUI com persistência local e em nuvem; e (iv) avaliar a usabilidade e a percepção de utilidade do aplicativo junto a usuários reais.

A relevância do trabalho está em contribuir com uma proposta de ferramenta acessível para um público que, apesar de representar mais da metade dos estabelecimentos abertos no país em 2024 (RECEITA FEDERAL apud CÂMARA MUNICIPAL, 2025), ainda conta com poucas soluções digitais pensadas especificamente para sua realidade, geralmente marcada por baixo investimento inicial em tecnologia e forte dependência do celular como principal dispositivo de trabalho.

Este documento está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico sobre MEI, inclusão financeira e aplicativos móveis de gestão; a Seção 3 descreve a metodologia de Design Science Research adotada; a Seção 4 apresenta os resultados obtidos com o protótipo e os testes de usabilidade; e a Seção 5 traz as conclusões e propostas de trabalhos futuros.

2. Referencial Teórico

O Microempreendedor Individual (MEI) constitui um dos principais vetores de inclusão socioeconômica e formalização do trabalho no Brasil, ultrapassando a marca de 13,1 milhões de registros ativos e registrando mais de 3,8 milhões de novas formalizações em 2025 (PODER360, 2025; SEBRAE, 2025). Não obstante sua relevância macroeconômica, grande parte desses empreendimentos opera sob condições operacionais vulneráveis, marcadas pela ausência de separação formal entre as contas financeiras pessoais e corporativas, falta de controle sistemático de estoque e reduzida capacidade preditiva de fluxo de caixa.

Nesse cenário, identifica-se como situação-problema a incapacidade recorrente dos pequenos empreendedores em antecipar crises de liquidez e insolvência antes que restrições de crédito severas se concretizem. Embora a literatura internacional examine há décadas o risco de crédito em pequenos negócios a partir de registros governamentais — como os mantidos pela U.S. Small Business Administration (LI; MICKEL; TAYLOR, 2018) —, o ecossistema brasileiro carece de bases de dados abertas, rotuladas e suficientemente volumosas sobre insolvência em MEIs, configurando uma lacuna empírica relevante.

A motivação central deste estudo vincula-se ao projeto de conclusão de curso do grupo: o desenvolvimento do Grafito, aplicativo móvel voltado à gestão financeira e de estoque de MEIs. Em entrevistas exploratórias, observou-se que a atuação dos gestores é predominantemente reativa diante de descompassos financeiros. Desse modo, torna-se

indispensável conceber um componente analítico inteligente capaz de classificar o perfil de risco com base em dados operacionais observáveis.

O objetivo geral desta pesquisa é desenvolver e avaliar um modelo de aprendizado de máquina supervisionado, treinado sobre registros reais de financiamentos a pequenas empresas, capaz de prever o desfecho de adimplemento ou inadimplência contratual.

Para consecução do objetivo geral, definem-se os seguintes objetivos específicos:

1. Obter, limpar e estruturar os dados brutos da SBA, saneando valores monetários textuais, imputando variáveis nulas e consolidando a variável-alvo binária;

Executar análise exploratória multivariada (EDA) investigando a distribuição do risco por segmento econômico, porte da empresa e localização espacial;

2. Construir novas características derivadas (engenharia de atributos), incluindo razão de cobertura de garantia governamental e proporção de capital por colaborador;
3. Treinar, calibrar e comparar o desempenho preditivo de classificadores supervisionados (Regressão Logística, Random Forest e Gradient Boosting) com auxílio da biblioteca scikit-learn;
4. Avaliar os modelos por meio de matrizes de confusão e métricas direcionadas ao desbalanceamento de classes, priorizando sensibilidade (recall) e a métrica AUC-ROC;
5. Discutir os limites teóricos e operacionais da transferência de padrões comportamentais de bases norte-americanas para a realidade institucional do MEI brasileiro.

A relevância deste trabalho repousa na criação de um arcabouço preditivo metodológico reproduzível para mitigação de assimetrias informacionais em microfinanças. O artigo está organizado em seis seções: a Seção 2 delinea o referencial teórico; a Seção 3 formaliza a metodologia e o pré-processamento; a Seção 4 apresenta os resultados e a discussão dos experimentos analíticos; a Seção 5 conclui o trabalho e sugere direções futuras; e a Seção 6 traz as referências bibliográficas.

3. Metodologia

A pesquisa possui natureza aplicada e abordagem quantitativa, orientando-se pela Opção Framework ao adotar o ferramental analítico do ecossistema scikit-learn sob a linguagem Python. O desenho metodológico organiza-se nas etapas sequenciais descritas a seguir.

3.1 Base de Dados e Dicionário de Variáveis

A base empírica selecionada é o SBA National Dataset, mantido pela U.S. Small Business Administration e tornado acessível publicamente via Kaggle. O conjunto original reúne

899.164 registros de contratos de empréstimo aprovados entre os anos de 1987 e 2014, contemplando 27 atributos primários. A Tabela 1 sintetiza as principais variáveis reservadas para o pipeline preditivo.

Atributo	Descrição Conceitual e Operacional
LoanNr_ChkDgt	Identificador numérico exclusivo do contrato (chave primária excluída do treino).
Name / City / State / Zip	Identificação cadastral e coordenadas geográficas da firma tomadora.
Bank / BankState	Identificação e localização federativa da instituição financeira operadora do crédito.
NAICS	Código de classificação setorial econômica (North American Industry Classification System).
ApprovalDate / ApprovalFY	Data de homologação e ano fiscal do registro de concessão do financiamento.
Term	Prazo total de amortização contratado (em meses).
NoEmp	Quadro efetivo de empregados vinculados à empresa no momento do pedido.
NewExist	Classificação temporal do negócio (1 = Empresa Estabelecida; 2 = Nova Empresa).
CreateJob / RetainedJob	Postos de trabalho formalmente gerados ou mantidos em virtude dos recursos aportados.
UrbanRural	Localização de domicílio (1 = Urbano; 2 = Rural; 0 = Não Identificado).
RevLineCr / LowDoc	Sinalizadores binários de linha de crédito rotativo e rito processual simplificado.
DisbursementGross	Montante financeiro nominal total desembolsado à conta do mutuário.
GrAppv / SBA_Appv	Valor total aprovado pela instituição bancária e montante garantido pelo fundo da SBA.
MIS_Status (Variável-Alvo)	Desfecho contábil do contrato: Quitado (PIF) ou Inadimplente/Baixa (CHGOFF).
ChgOffDate / ChgOffPrinGr	Data de homologação da inadimplência e montante do principal contabilizado em perda.

Tabela 1 – Dicionário de dados das variáveis selecionadas do SBA National Dataset.

3.2 Tratamento e Engenharia de Atributos

O pré-processamento estruturado em Python (pandas e NumPy) executa operações essenciais:

Normalização de Tipos de Dados: Remoção de caracteres de formatação monetária (símbolos de moeda, vírgulas de milhar) e conversão para dados numéricos contínuos em variáveis como DisbursementGross, GrAppv e SBA_Appv;

Filtragem e Rotulação do Alvo: Restrição do conjunto amostral aos contratos encerrados com desfecho resolutivo conhecido (PIF ou CHGOFF), formulando a variável binária Default, definida por 1 para ocorrência de inadimplência (CHGOFF) e 0 para contratos integralmente quitados (PIF);

Engenharia de Variáveis: Criação da proporção de garantia estatal mediante a razão entre SBA_Appv e GrAppv; computação do capital desembolsado por empregado através de $\text{DisbursementGross} / (\text{NoEmp} + 1)$; e agregação do setor econômico primário utilizando os dois primeiros dígitos do código setorial NAICS.

3.3 Modelagem e Validação Experimental

O particionamento amostral adota divisão estratificada na proporção de 75% para treinamento e 25% para teste independente. Variáveis nominais e categóricas (como setor derivado, estado federativo e regime operacional) são tratadas por codificação One-Hot Encoding, ao passo que as variáveis numéricas passam por escalonamento padrão. Para a classificação binária de inadimplência, estabeleceu-se a comparação entre três famílias algorítmicas implementadas via scikit-learn:

Regressão Logística: Classificador paramétrico linear aplicado como referencial analítico de linha de base (baseline);

Random Forest: Método ensemble fundamentado em comitês de árvores de decisão e amostragem aleatória por bagging;

Gradient Boosting: Abordagem ensemble sequencial que minimiza a função de perda residual por descida de gradiente.

O severo desbalanceamento de classes é tratado por ajuste de penalização na função de custo (`class_weight='balanced'`). A validação dos modelos é conduzida por validação cruzada k-fold estratificada, recorrendo a métricas direcionadas ao risco, em particular a sensibilidade (recall) da classe de inadimplência, F1-score ponderado e área sob a curva ROC (AUC-ROC).

3.4 Considerações Éticas e Responsabilidade em IA

Em consonância com as diretrizes de ética na inteligência artificial e em observância aos preceitos da Lei Geral de Proteção de Dados (LGPD), atesta-se que a base do SBA National Dataset é pública e desprovida de dados pessoais sensíveis identificáveis. O grupo assume o compromisso ético de explicitar que o modelo reflete relações econômicas dos Estados Unidos e não deve operar como instrumento automatizado de exclusão creditícia para MEIs nacionais. Sua finalidade reside estritamente no apoio à conscientização financeira do empreendedor no aplicativo Grafito, exigindo validações com dados locais antes de qualquer aplicação em ambiente de produção.

4. Resultados e discussão

O planejamento experimental e as análises preliminares indicam que o acervo histórico do SBA National Dataset apresenta uma assimetria típica de carteiras garantidas de financiamento comercial: a classe de adimplemento (PIF) concentra expressiva maioria frente à classe de perda contábil (CHGOFF). Esse comportamento reitera a necessidade de não se utilizar a acurácia global como métrica isolada de sucesso, priorizando a calibração do limiar de decisão para maximizar o recall da inadimplência sem gerar falso-positivos proibitivos.

Na dimensão setorial, as observações históricas indicam comportamentos díspares entre segmentos: áreas ligadas à hotelaria, serviços de alimentação e comércio de rua registram historicamente maior sensibilidade a ciclos econômicos negativos e maior incidência de inadimplência do que setores atacadistas ou profissionais. Adicionalmente, negócios recentes (categorizados com código 2 na variável NewExist) manifestam taxas de risco sensivelmente superiores em relação a estabelecimentos já maduros, confirmando que a inexperience de mercado atua como amplificador da vulnerabilidade financeira.

Quanto ao desempenho preditivo esperado, projeta-se que os comitês de árvores (*Random Forest* e *Gradient Boosting*) superem a regressão linear logística clássica em virtude das interações não lineares entre o prazo contratual (Term) e a razão de cobertura estatal. O modelo de feature importance deverá atestar o percentual de garantia estatal e o prazo de pagamento como os preditores de maior relevância estatística. Na transposição reflexiva para o contexto brasileiro dos MEIs, destaca-se que variáveis de fluxo operacional contínuo (entradas, saídas e giro de estoque) assumirão peso ainda mais determinante no Grafito do que a presença de garantias formais, dada a baixa cobertura de avais estatais para microempresários individuais autônomos no Brasil.

5. Conclusão

O presente artigo consolidou a modelagem conceitual e o arcabouço metodológico do projeto GrafitoIA voltado à estimativa do risco de inadimplência em operações financeiras de pequenos negócios, empregando algoritmos supervisionados de aprendizado de máquina sobre o SBA National Dataset. Por meio da estruturação de rotinas de limpeza, engenharia de atributos de garantia governamental e desenho de validação estratificada, o trabalho fundamenta a utilização de técnicas quantitativas para mitigar assimetrias de informação no universo das pequenas empresas.

Dentre as contribuições do estudo, destacam-se a formalização de um pipeline de preparação analítica reproduzível para bases de dados de crédito desbalanceadas e a análise crítica das condições de transferabilidade entre modelos econômicos distintos. A principal limitação metodológica identificada consiste na utilização exclusiva de dados históricos norte-americanos, cujas particularidades regulatórias divergem da estrutura tributária e creditícia do MEI brasileiro.

Para as etapas subsequentes do projeto (etapa N2), planeja-se a execução integral dos scripts de sintonia fina e otimização hiperparamétrica dos classificadores scikit-learn, a exploração de técnicas de explicabilidade algorítmica (SHAP e LIME) para interpretação transparente das previsões e a validação do componente analítico como protótipo consultivo no aplicativo móvel Grafito.

6. Referências bibliográficas

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6023: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.

GÉRON, A. Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow. Rio de Janeiro: Alta Books, 2021.

JAMES, G. et al. An Introduction to Statistical Learning: with Applications in Python. New York: Springer, 2023.

LI, M.; MICKEL, A.; TAYLOR, S. "Should This Loan be Approved or Denied?": A Large Dataset with Class Assignment Guidelines. Journal of Statistics Education, v. 26, n. 1, p. 55-66, 2018.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

PODER360. Abertura de MEIs bate recorde no Brasil em 2025. São Paulo: Poder360, 2025.

RUSSELL, S.; NORVIG, P. Inteligência Artificial. Rio de Janeiro: LTC, 2021.

SEBRAE. Panorama Econômico dos Pequenos Negócios. Brasília: SEBRAE, 2025.

TOKTOGARAEV, M. Should This Loan Be Approved Or Denied? Kaggle, 2020.

UNIVERSIDADE PRESBITERIANA MACKENZIE. Guia do TCC: Orientações gerais para a elaboração do trabalho de conclusão dos cursos de graduação. São Paulo: UPM, 2021.

